

# Αναγνώριση Προτύπων Θέμα Εξαμήνου

Αναγνωστόπουλος Βασίλης - Θάνος (ΜΠΠΛ 13002)  
Βελισσαρίου Κυριάκος (ΜΠΠΛ 13005)

Αθήνα, 2014

# Περιεχόμενα

|   |           |
|---|-----------|
| <b>1 Άσκηση 1η - Artificial Immune System</b> | <b>1</b>  |
| 1.1 Εκφώνηση . . . . .                        | 1         |
| 1.2 Λύση . . . . .                            | 1         |
| <b>2 Άσκηση 2η - Swarm Intelligence</b>       | <b>3</b>  |
| 2.1 Εκφώνηση . . . . .                        | 3         |
| 2.2 Λύση . . . . .                            | 3         |
| 2.2.1 Εισαγωγή . . . . .                      | 3         |
| 2.2.2 Ορισμός - Αρχές . . . . .               | 3         |
| 2.2.3 Κυριότεροι αλγόριθμοι σμήνους . . . . . | 4         |
| <b>3 Άσκηση 3η</b>                            | <b>4</b>  |
| 3.1 Εκφώνηση . . . . .                        | 4         |
| 3.2 Λύση . . . . .                            | 4         |
| <b>4 Άσκηση 4η - Fuzzy Logic Systems</b>      | <b>4</b>  |
| 4.1 Εκφώνηση . . . . .                        | 4         |
| 4.2 Ασαφής Λογική . . . . .                   | 4         |
| 4.3 Συστήματα ασαφούς λογικής . . . . .       | 6         |
| <b>5 Άσκηση 5η</b>                            | <b>7</b>  |
| 5.1 Εκφώνηση . . . . .                        | 7         |
| 5.2 Λύση . . . . .                            | 7         |
| <b>Βιβλιογραφία</b>                           | <b>14</b> |

## Κατάλογος σχημάτων

|   |    |
|---|----|
| 4.1 Παραδείγματα συναρτήσεων μελών [4] . . . . .  | 5  |
| 4.2 Σύστημα ασαφούς λογικής [5, 15] . . . . .   | 6  |
| 4.3 Σύστημα ασαφούς λογικής (2) [4] . . . . .   | 7  |
| 5.1 Τα δεδομένα εκφράσεων προσώπου . . . . .  | 11 |
| 5.2 Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την μέση σύνδεση και την ευκλείδεια απόσταση . . . . .  | 11 |
| 5.3 Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την μέση σύνδεση και την απόσταση mahalanobis . . . . . | 12 |
| 5.4 Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την μέση σύνδεση και την απόσταση manhattan . . . . .   | 12 |
| 5.5 Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την μονή σύνδεση και την ευκλείδεια απόσταση . . . . .  | 12 |
| 5.6 Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την πλήρη σύνδεση και την ευκλείδεια απόσταση . . . . . | 13 |

## Κατάλογος αλγορίθμων

|  |   |
|--|---|
| 1 Βασικός αλγόριθμος ΤΑΣ [4] . . . . . | 2 |
|--|---|

# Κατάλογος πηγαίου κώδικα

|   |                                |   |
|---|--------------------------------|---|
| 1 | Ο κώδικας του matlab . . . . . | 8 |
|---|--------------------------------|---|

# 1 Άσκηση 1η - Artificial Immune System

## 1.1 Εκφώνηση

Να γίνει πλήρης βιβλιογραφική έρευνα με βάση τις λέξεις κλειδιά "Artificial Immune System".

## 1.2 Λύση

Το φυσικό ανοσοποιητικό σύστημα είναι ένα πολύπλοκο σύστημα για την λειτουργία του οποίου έχουν γραφτεί αρκετές δημοσιεύσεις για το πως λειτουργεί [9]. Εκτός από την ικανότητα του να καταπολεμά ξένα κύτταρα και μολύνσεις προς τον οργανισμό, διαθέτει μνήμη, μία ιδιαίτερα σημαντική ιδιότητα, καθ' ότι του επιτρέπει να αναγνωρίζει και να αντιμετωπίζει πιο άμεσα σε μία εισβολή από παθογόνα, που έχουν προσβάλει και παλιότερα τον οργανισμό.

Ένα τεχνητό ανοσοποιητικό σύστημα (ΤΑΣ - αγγλ. Artificial Immune System) μοντελοποιεί την ικανότητα του φυσικού ανοσοποιητικού συστήματος των σπονδυλωτών να ανιχνεύει κύτταρα ξένα προς τον οργανισμό. Το αποτέλεσμα είναι ένα νέο υπολογιστικό μοντέλο το οποίο είναι ικανό να αναγνωρίζει πρότυπα και εφαρμόζεται κυρίως στην ανίχνευση ανωμαλιών [4, 6].

Ο ορισμός και η ανάπτυξη ενός πλήρους ΤΑΣ περιλαμβάνει, γενικά, μία πληθώρα θεμάτων, μεταξύ των οποίων είναι [4, 14]:

- υβριδικές δομές και αλγόριθμοι, οι οποίοι λαμβάνουν υπ' όψιν τους μηχανισμούς του ανοσοποιητικού συστήματος όπως την ανίχνευση ξένων προτύπων με μία ορισμένη συγγένεια και την αποθήκευση πληροφορίας και την επαναχρησιμοποίηση της.
- υπολογιστικοί αλγόριθμοι βασισμένοι σε αρχές του ανοσοποιητικού συστήματος, όπως είναι η κατανεμημένη επεξεργασία, η αρχή της επιλογής των κλώνων και η θεωρία του ανοσοποιητικού δικτύου.

Χρησιμοποιώντας τα παραπάνω ο Engelbrecht παραθέτει τον βασικό αλγόριθμο για την δημιουργία ΤΑΣ (βλέπε αλγόριθμο 1).

Κάθε κομμάτι του αλγορίθμου αναλύεται πιο κάτω [4]:

**Αρχικοποίηση  $C$  και καθορισμός  $D_T$ :** Ο πληθυσμός  $C$  μπορεί να είναι είτε δημιουργημένος από τυχαία δημιουργημένα τεχνητά λεμφοκυττάρων <sup>1</sup> (ΤΛ) ή από κάποια άλλη μέθοδο η οποία εξαρτάται από τον αλγόριθμο του ΤΑΣ.

**Συνθήκη τερματισμού του while:** Στα περισσότερα μοντέλα των ΤΑΣ, η συνθήκη τερματισμού βασίζεται στην σύγκλιση του πληθυσμού των ΤΛ ή από ένα συγκεκριμένο αριθμό επαναλήψεων.

**Επιλογή του υποσυνόλου  $S$  των ΤΛ:** Το υποσύνολο  $S$  μπορεί να είναι ολόκληρο το σύνολο  $P$  ή ένα τυχαίος αριθμός ΤΛ από το  $P$ .

<sup>1</sup>Το λεμφοκύτταρο αποτελεί είδος λευκού αιμοσφαιρίου το οποίο το συναντιόνται στο φυσικό ανοσοποιητικό σύστημα και είναι επιφορτισμένα με την άμυνα του οργανισμού έναντι σε λοιμώξεις [10].

---

**Αλγόριθμος 1** Βασικός αλγόριθμος ΤΑΣ [4]

---

Αρχικοποίηση ενός σύνολου τεχνικών λεμφοκυττάρων (ΤΛ) ως πληθυσμός  $C$ ;  
Καθορισμός των προτύπων των αντιγόνων ως σύνολο εκπαίδευσης  $D_T$ ;  
while κάποια συνθήκη τερματισμού είναι αναληθείς do  
    for κάθε πρότυπο αντιγόνου  $z_p \in D_T$  do  
        Επιλογή ενός υποσυνόλου ΤΛ για έκθεση στο  $z_p$ , σαν πληθυσμός  $S \leq C$ ;  
        for για κάθε ΤΛ  $x_i \in S$  do  
            Υπολογισμός την ομοιότητα του αντιγόνου μεταξύ  $z_p, x_i$ ;  
        end  
        Επιλογή ενός υποσυνόλου ΤΛ που έχουν την μεγαλύτερη ομοιότητα  
        αντιγόνων σαν πληθυσμός  $H \leq S$ ;  
        Προσαρμογή των ΤΛ με κάποια μέθοδο επιλογής, με βάση την υπολογισμένη  
        ομοιότητα και/ή την ομοιότητα του δικτύου των ΤΛ στο  $H$ ;  
        Ανανέωση του βαθμού ομοιότητας των ΤΛ στο  $H$ ;  
    end  
end

---

**Υπολογισμός της ομοιότητας του αντιγόνου:** Η ομοιότητα του αντιγόνου (αγγλ. antigen affinity) είναι η μέτρηση της "συγγένειας" που υπάρχει μεταξύ των ΤΛ και των προτύπων των αντιγόνων.

**Επιλογή του υποσυνόλου  $H$  των ΤΛ:** Σε κάποια από τα μοντέλα των ΤΑΣ, η επιλογή της καλύτερης ομοιότητας των ΤΛ βασίζεται σε κάποιο κατώφλι ομοιότητας. Έτσι το υποσύνολο  $H$  μπορεί να είναι ολόκληρο το  $S$ , αναλόγως ποιο είναι το κατώφλι ομοιότητας.

**Υπολογισμός της ομοιότητας του δικτύου:** Αυτή είναι η μέτρηση της ομοιότητας μεταξύ δύο ΤΛ. Τα διάφορα μέτρα ομοιότητας ενός δικτύου είναι τα ίδια με εκείνα των αντιγόνων.. Ένα καθορισμένο κατώφλι ομοιότητας προσδιορίζει αν δύο ή περισσότερα ΤΛ συνδέονται για να σχηματίσουν ένα δίκτυο.

**Ανανέωση του βαθμού ομοιότητας των ΤΛ στο  $H$ :** Είναι η διαδικασία με την οποία τα ΤΛ ωριμάζουν. Η διαδικασία ωρίμανσης αλλάζει ανάλογα με το μοντέλο του ΤΑΣ.

Έχουν προταθεί αρκετοί αλγόριθμοι για την επίλυση των ΤΑΣ όπως [4]:

**το κλασσικό μοντέλο:** σε αυτό το μοντέλο το ΤΑΣ "εκπαιδεύει" τα ΤΛ σε ένα σύνολο προτύπων του εαυτού του έτσι ώστε να είναι "αυτο-ανεκτικά", δηλαδή να έχουν την ικανότητα να αναγνωρίζουν τα πρότυπα μεταξύ του εαυτού και του μη εαυτού [4]. Βασίζεται στα Τ-λεμφοκύτταρα του φυσικού ανοσοποιητικού συστήματος τα οποία αναγνωρίζουν τα κύτταρα του οργανισμού και επιτίθενται μόνο στα ξένα κύτταρα. Ένα από τα μοντέλα των ΤΑΣ που βασίζονται στο κλασσικό μοντέλο είναι το μοντέλο της αρνητικής επιλογής.

**το μοντέλο επιλογής του κλώνου:** σε αυτό το μοντέλο των ΤΑΣ η επιλογή ενός συνόλου ΤΛ γίνεται με βάση εκείνα τα οποία έχουν τον υψηλότερο βαθμό ομοιότητας μαζί με ένα πρότυπο μη εαυτού. Έπειτα τα επιλεγμένα

ΤΛ κλωνοποιούνται και μεταλλάσσονται σε μία προσπάθεια να έχουν υψηλότερη ομοιότητα με το πρότυπο μη εαυτού.

**το μοντέλου του δικτύου:** σε αυτό το μοντέλο των ΤΑΣ τα ΤΛ αλληλεπιδρούν μεταξύ τους έτσι ώστε να μάθει το ένα από το άλλο την μορφή του προτύπου μη εαυτού, με αποτέλεσμα να δημιουργείται ένα δίκτυο από ΤΛ.

**το μοντέλο του κινδύνου:** σε αυτό το μοντέλο, σε αντίθεση με το κλασσικό μοντέλο, το μοντέλο του κινδύνου διαφοροποιείται αναγνωρίζοντας το τί είναι επικίνδυνο και τί είναι μη-επικίνδυνο αντί να βρίσκει πρότυπα εαυτού και μη-εαυτού.

Τα τεχνητά ανοσοποιητικά συστήματα έχουν εφαρμοστεί με επιτυχία σε πολλές περιοχές, όπως στην ανίχνευση ανωμαλιών, στην ταξινόμηση δεδομένων, στην ανίχνευση ιών, στην αναγνώριση προτύπων κ.λ.π. [6, 4, 14].

## 2 Άσκηση 2η - Swarm Intelligence

### 2.1 Εκφώνηση

Να γίνει πλήρης βιβλιογραφική έρευνα με βάση τις λέξεις κλειδιά "Swarm Intelligence".

### 2.2 Λύση

#### 2.2.1 Εισαγωγή

Στην παρούσα ερώτηση θα επιχειρηθεί μια σύντομη έκθεση η οποία θα αφορά τον όρο Νοημοσύνη Σμήνους (Swarm Intelligence). Η δομή που ακολουθείται είναι η εξής: Αρχικά, θα δοθεί ο ορισμός της Νοημοσύνης Σμήνους και θα αναφερθούν οι γενικές αρχές της. Στην συνέχεια, θα γίνει μια σύντομη επισκόπηση στις κατηγορίες αλγορίθμων νοημοσύνης σμήνους. Τέλος, στον επίλογο, θα αναφερθούν μια σειρά από προβλήματα, στην επίλυση των οποίων βρίσκουν εφαρμογή οι προαναφερθέντες αλγόριθμοι.

#### 2.2.2 Ορισμός - Αρχές

Σύμφωνα με τους Gerardo Beni και Jim Wang [2], η Νοημοσύνη Σμήνους είναι η συλλογική συμπεριφορά αποκεντρωμένων αυτο-οργανωμένων συστημάτων, φυσικών ή τεχνητών.

Όπως είναι προφανές, τα φυσικά συστήματα νοημοσύνης σμήνους προϋπήρχαν των τεχνητών και μάλιστα, στάθηκαν η αφορμή για την δημιουργία των τελευταίων. Τα φυσικά συστήματα που μελετήθηκαν αρχικά περιελάμβαναν κοπάδια ψαριών, σμήνη πτηνών και μελισσών καθώς και αποικίες μυρμηγκιών. Αυτό το οποίο εντυπωσίασε του ερευνητές και που προσπάθησαν να εκμεταλλευτούν με την δημιουργία τεχνητών συστημάτων νοημοσύνης σμήνους, είναι η δυνατότητα των συστημάτων αυτών, να πετυχαίνουν πολύπλοκους στόχους ενώ τα ίδια είναι αποτελούμενα από απλές οντότητες περιορισμένων δυνατοτήτων. Ένα ακόμα εντυπωσιακό στοιχείο, σύμφωνα και με τον ορισμό που

δόθηκε, είναι ότι οι απλές αυτές οντότητες δεν κατευθύνονται από κάποια κεντρική οντότητα [1], αλλά δρουν αποκεντρωμένα. Για παράδειγμα, στις αποικίες μυρμηγκιών, τα μυρμηγκία είναι ικανά όχι μόνο να βρουν τον δρόμο, αλλά και το συντομότερο μονοπάτι προς την τροφή τους. Αυτό το πετυχαίνουν με την έκκριση μια φερορμόνης. Συνεπώς, τα μυρμηγκία θα ακολουθούν μονοπάτια τα οποία έχουν έντονη ποσότητα φερορμόνης για να τα διεγείρει. Τελικά, το συντομότερο μονοπάτι προς την τροφή θα συγκεντρώνει όλο και μεγαλύτερο αριθμό μυρμηγκιών, έτσι η φερορμόνη σε αυτό το μονοπάτι θα είναι εντονότερη [3].

Στο επόμενο υποκεφάλαιο παρουσιάζονται κάποιοι από τους σημαντικότερους αλγόριθμους Νοημοσύνης Σμήνους οι οποίοι προήλθαν από μελέτη φαινομένων σαν αυτά που αναφέρθηκαν στην προηγούμενη παράγραφο.

### 2.2.3 Κυριότεροι αλγόριθμοι σμήνους

## 3 Άσκηση 3η

### 3.1 Εκφώνηση

Να γίνει πλήρης βιβλιογραφική έρευνα με βάση τις λέξεις κλειδιά "Evolutionary Computing" και Genetic Algorithms.

### 3.2 Λύση

σελ. 80

## 4 Άσκηση 4η - Fuzzy Logic Systems

### 4.1 Εκφώνηση

Να γίνει πλήρης βιβλιογραφική έρευνα με βάση τις λέξεις κλειδιά "Fuzzy Logic Systems".

### 4.2 Ασαφής Λογική

Η ασαφής λογική πρόκειται για μία γενίκευση της συμβατικής Θεωρίας Συνόλων και είναι μία πλειότιμη λογική η οποία ασχολείται με την λογική σαν μία προσέγγιση και όχι σαν κάτι σταθερό και ακριβές [4, 15, 7, 13].


Η ασαφής λογική βασίζεται στα ασαφή σύνολα. Σε σύγκριση με τα δυαδικά σύνολα (οι μεταβλητές των οποίων μπορούν να λάβουν την τιμή "αλήθεια" ή "ψευδές"), τα ασαφή σύνολα περιέχουν αντικείμενα τα οποία ικανοποιούν ανακριβείς ιδιότητες και μπορεί να έχουν μία τιμή αληθείας η οποία κυμαίνεται στο βαθμό μεταξύ 0 και 1 σε αυτό το σύνολο (βλ. εξίσωση (1)) [11].

$$\mu_A : X \rightarrow [0, 1] \quad (1)$$


όπου  $X$  ο χώρος των αντικειμένων. Αν  $x$  ένα γενικό αντικείμενο του  $X$  με  $x \in X$  τότε το  $\mu_A(x)$  δείχνει την βεβαιότητα με την οποία το στοιχείο  $x$  ανήκει στο ασαφή σύνολο  $A$ .

Ο βαθμός συμμετοχής σε ένα ασαφές σύνολο υποδηλώνει την βεβαιότητα (ή την αβεβαιότητα) ότι το στοιχείο ανήκει σε αυτή την ομάδα. Η ασαφής λογική χρησιμοποιείται για να χειριστεί την έννοια της μερικής αλήθειας, όπου η τιμή της αλήθειας μπορεί να κυμαίνεται μεταξύ εντελώς αλήθειας και εντελώς ψευδής. Τα ασαφή σύνολα επιτρέπουν την μοντελοποίηση των αβεβαιοτήτων της φυσικής γλώσσας και μπορούν να χρησιμοποιηθούν τόσο για διακριτούς ή/και συνεχόμενους χώρους [4, 15, 7].


Για τον πλήρη ορισμό ενός ασαφές συνόλου χρειαζόμαστε ακόμα και την συνάρτηση μέλος του ασαφούς συνόλου, η οποία χρησιμοποιείται για να συνδέσει τον βαθμό συμμετοχής κάθε στοιχείου  $x$  του χώρου των αντικειμένων με το αντίστοιχο ασαφές σύνολο. Οι συναρτήσεις μέλη μπορεί να έχουν οποιοδήποτε σχήμα ή τύπο (βλ. σχήμα 4.1). [4].




**(α') Τριγωνική συνάρτηση μέλους**



**(β') Τραπεζοειδής συνάρτηση μέλους**



**(γ') Λογιστική συνάρτηση μέλους**




**(δ') Γκαουσιανή συνάρτηση μέλους**

**Σχήμα 4.1: Παραδείγματα συναρτήσεων μελών [4]**

Τέλος στην ασαφή λογική μπορούν να χρησιμοποιηθούν και λεκτικές μεταβλητές (αγγλ. linguistic variables). Με τον όρο λεκτική μεταβλητή εννοούμε τις μεταβλητές των οποίων οι τιμές είναι λέξεις σε μία φυσική ή τεχνική γλώσσα [12]. Οι λεκτικές μεταβλητές επιτρέπουν την μετατροπή της φυσικής γλώσσας σε λογικές ή αριθμητικές παραστάσεις, οι οποίες παρέχουν τα εργαλεία για την προσεγγιστική λογική [4].





Σχήμα 4.2: Σύστημα ασαφούς λογικής [5, 15]

### 4.3 Συστήματα ασαφούς λογικής


Η σχεδίαση συστημάτων ασαφούς λογικής (ΣΑΛ) είναι ένας από τους μεγαλύτερους τομείς εφαρμογής της ασαφούς λογικής [4]. Ένα σύστημα ασαφούς λογικής (αγγλ. Fuzzy Logic Systems - FLS) είναι μία γραμμική απεικόνιση ενός διανύσματος δεδομένων εισόδου (χαρακτηριστικά) σε μία βαθμωτή έξοδο (η οποία αποσυντίθεται σε μία συλλογή από ανεξάρτητες πολλαπλές εισόδου/μονής εξόδου σύστημα - βλέπε σχήμα 4.2) [5, 15].

Στα ΣΑΛ, η δυναμική συμπεριφορά του συστήματος περιγράφεται από ένα σύνολο λεκτικών ασαφών κανόνων της μορφής AN - TOTE [4, 15]. Σε συνδυασμό, τα ασαφή σύνολα και οι λεκτικοί κανόνες αποτελούν την γνωσιακή βάση ενός ΣΑΛ. Ακόμα ένα ΣΑΛ αποτελείται από άλλα 3 στοιχεία:

**ασαφοποιητής (αγγλ. fuzzifier):** ο σκοπός του ασαφοποιητή είναι η εύρεση μίας ασαφούς τιμής από μη ασαφές τιμές εισόδου. Αυτό επιτυγχάνεται χρησιμοποιώντας την συνάρτηση μέλους που σχετίζεται με κάθε ασαφές σύνολο στα δεδομένα εισόδου. Δηλαδή, οι τιμές στα δεδομένα εισόδου αντιστοιχούνται σε βαθμούς συμμετοχής σε ασαφή σύνολα [4].

**συμπερασματοποιητής (αγγλ. inference):** ο σκοπός του συμπερασματοποιητή (αγγλ. inference) είναι να χαρτογραφήσει τις ασαφές εισόδους (όπως λαμβάνονται από την διαδικασία της ασαφοποίησης (αγγλ. fuzzifier) στους λεκτικούς κανόνες και να παράγουν μία αποσαφηνισμένη (αγγλ. fuzzified) έξοδο για κάθε κανόνα [4].

**αποσαφηνιστής (αγγλ. defuzzifier):** ο σκοπός του αποσαφηνιστή (αγγλ. defuzzifier) είναι η παραγωγή μίας σαφούς εξόδου για το ΣΑΛ από το ασαφές σύνολο που προέκυψε ως έξοδος από τον συμπερασματοποιητή. Δηλαδή παραγάγει σε αυτό το στάδιο γίνεται η μετατροπή των ασαφών κανόνων σε μία βαθμωτή τιμή ή γενικά σε μία ασαφή μεταβλητή [15, 4]. Στην βιβλιογραφία έχουν προταθεί αρκετοί αποσαφηνιστές για την εύρεση της βαθμωτής τιμής που αναπαριστά την ενέργεια που πρέπει να πραγματοποιηθεί.



**Σχήμα 4.3: Σύστημα ασαφούς λογικής (2) [4]**

Καθένα από αυτά τα στοιχεία εκτελεί μία συγκεκριμένη εργασία κατά την διαδικασία συλλογισμού (αγγλ. reasoning process). Τα διαφορετικά στοιχεία ενός ΣΑΛ φαίνονται στο σχήμα 4.3.

## 5 Άσκηση 5η

### 5.1 Εκφώνηση

Να υλοποιηθούν αλγόριθμοι ιεραρχικής ομαδοποίησης δεδομένων και να εφαρμοστούν στα δεδομένα εκφράσεων προσώπου που θα σας παρασχεθούν.

### 5.2 Λύση

Η ιεραρχική ομαδοποίηση (αγγλ. hierarchical clustering) είναι μία μέθοδος ανάλυσης κλάσεων η οποία αναζητά να κατασκευάσει μία ιεραρχία ομάδων. Η ιεραρχική ομαδοποίηση έχει την ιδιότητα ότι τα δείγματα που ανήκουν στην ίδια ομάδα σε κάποιο επίπεδο να παραμένουν στην ίδια ομάδα σε υψηλότερα επίπεδα [8, 15].

Οι στρατηγικές ιεραρχικής ομαδοποίησης διακρίνονται σε δύο κατηγορίες [8, 15]:

**συγχωνευτικές (αγγλ. agglomerative):** Οι συγχωνευτικές (από κάτω προς τα πάνω) ξεκινούν από  $n$  ομάδες και δημιουργούν μία ακολουθία από διαδοχικές συγχωνεύσεις ομάδων.

**διαιρετικές (αγγλ. *divisive*):** Οι διαιρετικές (από πάνω προς τα κάτω) ξεκινούν με όλα τα δείγματα σε μία ομάδα και δημιουργούν μία ακολουθία από διαδοχικές διαιρέσεις ομάδων.

Τα αποτελέσματα της ιεραρχικής ομαδοποίησης συνήθως απεικονίζονται σε ένα δενδρόγραμμα (αγγλ. *dendrogram*).

Για να διαπιστωθεί ποιες ομάδες θα πρέπει να συγχωνευτούν (ή αντιστοίχως να διαιρεθούν), θα πρέπει να υπάρχει ένα μέτρο της ανομοιοότητας μεταξύ των ομάδων των παρατηρήσεων. Στην πλειοψηφία των ιεραρχικών ομαδοποιήσεων αυτό επιτυγχάνετε με την χρήση ενός κατάλληλου μέτρου (ένα μέτρο της απόστασης μεταξύ των ζευγών των παρατηρήσεων - βλ. πίνακα 5.1), καθώς και ένα κριτήριο συνδέσεως (βλ. πίνακα 5.2) η οποία καθορίζει την ανομοιοότητα των συνόλων ως συνάρτηση των αποστάσεων κατά ζεύγη των παρατηρήσεων στα σύνολα [8].

| Όνομα                | Τύπος   |
|----------------------|---|
| Ευκλείδεια απόσταση  | $\ a - b\ _2 = \sqrt{\sum_i (a_i - b_i)^2}$   |
| Απόσταση manhattan   | $\ a - b\ _1 = \sum_i \ a_i - b_i\ $  |
| Μέγιστη απόσταση     | $\ a - b\ _\infty = \max_i \ a_i - b_i\ $   |
| Απόσταση mahalanobis | $\sqrt{(a - b)^\top S^{-1} (a - b)}$ , όπου $S$ είναι ο πίνακας συ-<br>μεταβλητότητας |

**Πίνακας 5.1: Ο πίνακας με τις αποστάσεις [8].**

| Όνομα           | Τύπος  |
|-----------------|--|
| Πλήρης σύνδεσης | $\max \{d(a, b) : a \in A, b \in B\}$                |
| Μονή σύνδεση    | $\min \{d(a, b) : a \in A, b \in B\}$                |
| Μέση σύνδεση    | $\frac{1}{AB} \sum_{a \in A} \sum_{b \in B} d(a, b)$ |

**Πίνακας 5.2: Ο πίνακας με τα κριτήρια σύνδεσης [8].**

Στον πηγαίο κώδικα 1 φαίνεται το script που γράφτηκε για τον υπολογισμό των ιεραρχικών ομαδοποιήσεων στο matlab.

**Πηγαίος κώδικας 1: Ο κώδικας του matlab**

```

1 % This script demonstrates the hierarchical clustering algorithm on a set of
2 % given data points.
3
4 %Initialize workspace.
5 clc
6 clear all
7
8 % Load data
9 X1 = csvread('features_1.csv');
10 X2 = csvread('features_2.csv');
11 X3 = csvread('features_3.csv');
12

```

```

13 % Store both sets of points in a single matrix.
14 X = [X1;X2;X3];
15
16 % Plot the labeled data points
17 figure('Name','Labeled Data Popints')
18 hold on
19 plot(X1(:,1),X1(:,2),'*r','LineWidth',1.4);
20 plot(X2(:,1),X2(:,2),'*b','LineWidth',1.4);
21 plot(X3(:,1),X3(:,2),'*g','LineWidth',1.4);
22 xlabel('x1');
23 ylabel('x2');
24 grid on
25 hold off
26
27 %Plot the unlabeled data points.
28 figure('Name','Unlabeled Data Popints')
29 hold on
30 plot(X(:,1),X(:,2),'*k','LineWidth',1.4);
31 xlabel('x1');
32 ylabel('x2');
33 grid on
34 hold off
35
36 % Create the hierarchical clustering dendrogram with euclidean distange
37 % and average linkage.
38 Y = pdist(X,'euclidean');
39 Z = linkage(Y,'average');
40 figure('Name','Hierarchical Dendrogram (average,euclidean)')
41 [H,T] = dendrogram(Z,0,'colorthreshold','default');
42 set(H,'LineWidth',2)
43
44 % Cluster data in three clusters.
45 T = clusterdata(X,'linkage','average','distance','euclidean',3);
46 figure('Name','Identified Clusters (average,euclidean)')
47 scatter(X(:,1),X(:,2),20,T,'filled')
48 grid on
49
50 % Create the hierarchical clustering dendrogram with mahalanobis distange
51 % and average linkage.
52 Y = pdist(X,'mahalanobis');
53 Z = linkage(Y,'average');
54 figure('Name','Hierarchical Dendrogram (average,mahalanobis)')
55 [H,T] = dendrogram(Z,0,'colorthreshold','default');
56 set(H,'LineWidth',2)
57
58 % Cluster data in three clusters.
59 T = clusterdata(X,'linkage','average','distance','mahalanobis',3);
60 figure('Name','Identified Clusters (average,mahalanobis)')
61 scatter(X(:,1),X(:,2),20,T,'filled')
62 grid on

```

```

63
64 % Create the hierarchical clustering dendrogram with cityblock distance
65 % and average linkage.
66 Y = pdist(X,'cityblock');
67 Z = linkage(Y,'average');
68 figure('Name','Hierarchical Dendrogram (average,cityblock)')
69 [H,T] = dendrogram(Z,0,'colorthreshold','default');
70 set(H,'LineWidth',2)
71
72 % Cluster data in three clusters.
73 T = clusterdata(X,'linkage','average','distance','cityblock',3);
74 figure('Name','Identified Clusters (average,cityblock)')
75 scatter(X(:,1),X(:,2),20,T,'filled')
76 grid on
77
78 % Create the hierarchical clustering dendrogram with euclidean distance
79 % and single linkage.
80 Y = pdist(X,'euclidean');
81 Z = linkage(Y,'single');
82 figure('Name','Hierarchical Dendrogram (single,euclidean)')
83 [H,T] = dendrogram(Z,0,'colorthreshold','default');
84 set(H,'LineWidth',2)
85
86 % Cluster data in three clusters.
87 T = clusterdata(X,'linkage','single','distance','euclidean',3);
88 figure('Name','Identified Clusters (single,euclidean)')
89 scatter(X(:,1),X(:,2),20,T,'filled')
90 grid on
91
92 % Create the hierarchical clustering dendrogram with euclidean distance
93 % and complete linkage.
94 Y = pdist(X,'euclidean');
95 Z = linkage(Y,'complete');
96 figure('Name','Hierarchical Dendrogram (complete,euclidean)')
97 [H,T] = dendrogram(Z,0,'colorthreshold','default');
98 set(H,'LineWidth',2)
99
100 % Cluster data in three clusters.
101 T = clusterdata(X,'linkage','complete','distance','euclidean',3);
102 figure('Name','Identified Clusters (complete,euclidean)')
103 scatter(X(:,1),X(:,2),20,T,'filled')
104 grid on

```


---

Στο σχήμα 5.1 φαίνονται τα χαρακτηριστικά όπως είναι ταξινομημένα στην πραγματικότητα και όπως τα αντιλαμβάνεται ο αλγόριθμος.


Για την καλύτερη κατανόηση της επίδρασης του μέτρου της απόστασης (βλ. πίνακα 5.1) και της απόστασης μεταξύ των ζευγών παρατηρήσεων (βλ. πίνακα 5.2) πραγματοποιήθηκαν μία σειρά από ιεραρχικές ταξινομήσεις. Στις 3 πρώτες (βλ. σχήμα 5.2 έως 5.4) διατηρήθηκε σταθερή η απόσταση μεταξύ των ζευγών (και συγκεκριμένα μέση σύνδεση) και άλλαξε ο τύπος της απόστασης

ενώ στα 2 τελευταία (βλ. σχήμα 5.5 έως 5.6) διατηρήθηκε ο τύπος της απόστασης σταθερός (και συγκεκριμένα ευκλείδεια) και άλλαζε η απόσταση μεταξύ των ζευγών.

Παρατηρούμε ότι οι συστάδες που δημιουργήθηκαν δεν άλλαξαν παρά μόνο στο σχήμα 5.3. Άρα οι συστάδες επηρεάζονται περισσότερο από την γεωμετρία του ίδιου του προβλήματος παρά από τις παραμέτρους που βάζουμε. Αντιθέτως το δενδρογράμμα άλλαζε κάθε φορά πράγμα που το καθιστά και ευαίσθητο στις παραμέτρους που τοποθετούμε στο πρόβλημα.





**(α') Τα ταξινομημένα δεδομένα**





**(β') Τα αταξινομημένα δεδομένα**

**Σχήμα 5.1: Τα δεδομένα εκφράσεων προσώπου**





**(α') Τα δενδρογράμματα των δεδομένων (β') Οι συστάδες που δημιουργήθηκαν**

**Σχήμα 5.2: Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την μέση σύνδεση και την ευκλείδεια απόσταση**





(α') Τα δένδρογραμμα των δεδομένα (β') Οι συστάδες που δημιουργήθηκαν

Σχήμα 5.3: Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την μέση σύνδεση και την απόσταση mahalanobis





(α') Τα δένδρογραμμα των δεδομένα (β') Οι συστάδες που δημιουργήθηκαν

Σχήμα 5.4: Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την μέση σύνδεση και την απόσταση manhattan



(α') Τα δένδρογραμμα των δεδομένα (β') Οι συστάδες που δημιουργήθηκαν

Σχήμα 5.5: Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την μονή σύνδεση και την ευκλείδεια απόσταση



**(α') Τα δένδρογραμμα των δεδομένα (β') Οι συστάδες που δημιουργήθηκαν**

**Σχήμα 5.6: Η ιεραρχική ομαδοποίηση των δεδομένων χρησιμοποιώντας την πλήρη σύνδεση και την ευκλείδεια απόσταση**



## Αναφορές

- [1] Hazem Ahmed and Janice Glasgow. Swarm intelligence: concepts, models and applications. *School of Computing, Queen's University*, 2012.
- [2] Gerardo Beni and Jing Wang. Swarm intelligence in cellular robotic systems. In *Robots and Biological Systems: Towards a New Bionics?*, pages 703--712. Springer, 1993.
- [3] Marco Dorigo. *Ant Colony Optimization and Swarm Intelligence: 5th International Workshop, ANTS 2006, Brussels, Belgium, September 4-7, 2006, Proceedings*, volume 4150. Springer Science & Business Media, 2006.
- [4] Andries P. Engelbrecht. *Computational Intelligence: An Introduction*. Wiley Publishing, 2nd edition, 2007. ISBN 0470035617.
- [5] J.M. Mendel. Fuzzy logic systems for engineering: a tutorial. *Proceedings of the IEEE*, 83(3):345--377, Mar 1995. ISSN 0018-9219. doi: 10.1109/5.364485.
- [6] Wikipedia. Artificial immune system --- Wikipedia, the free encyclopedia. [http://en.wikipedia.org/wiki/Artificial\\_immune\\_system](http://en.wikipedia.org/wiki/Artificial_immune_system), 2015. URL [http://en.wikipedia.org/wiki/Artificial\\_immune\\_system](http://en.wikipedia.org/wiki/Artificial_immune_system). [Πρόσβαση στις 20 Ιανουαρίου 2015].
- [7] Wikipedia. Fuzzy logic --- Wikipedia, the free encyclopedia. [http://en.wikipedia.org/wiki/Fuzzy\\_logic](http://en.wikipedia.org/wiki/Fuzzy_logic), 2015. URL [http://en.wikipedia.org/wiki/Fuzzy\\_logic](http://en.wikipedia.org/wiki/Fuzzy_logic). [Πρόσβαση στις 18 Ιανουαρίου 2015].
- [8] Wikipedia. Hierarchical clustering --- Wikipedia, the free encyclopedia. [http://en.wikipedia.org/wiki/Hierarchical\\_clustering](http://en.wikipedia.org/wiki/Hierarchical_clustering), 2015. URL [http://en.wikipedia.org/wiki/Hierarchical\\_clustering](http://en.wikipedia.org/wiki/Hierarchical_clustering). [Πρόσβαση στις 25 Ιανουαρίου 2015].
- [9] Wikipedia. Immune system --- Wikipedia, the free encyclopedia. [http://en.wikipedia.org/wiki/Immune\\_system](http://en.wikipedia.org/wiki/Immune_system), 2015. URL [http://en.wikipedia.org/wiki/Immune\\_system](http://en.wikipedia.org/wiki/Immune_system). [Πρόσβαση στις 24 Ιανουαρίου 2015].
- [10] Wikipedia. Immune system --- Wikipedia, the free encyclopedia. <http://el.wikipedia.org/wiki/%CE%9B%CE%B5%CE%BC%CF%86%CE%BF%CE%BA%CF%8D%CF%84%CF%84%CE%B1%CF%81%CE%BF>, 2015. URL <http://el.wikipedia.org/wiki/%CE%9B%CE%B5%CE%BC%CF%86%CE%BF%CE%BA%CF%8D%CF%84%CF%84%CE%B1%CF%81%CE%BF>. [Πρόσβαση στις 24 Ιανουαρίου 2015].
- [11] L.A. Zadeh. Fuzzy sets. *Information and Control*, 8(3):338 -- 353, 1965. ISSN 0019-9958. doi: [http://dx.doi.org/10.1016/S0019-9958\(65\)90241-X](http://dx.doi.org/10.1016/S0019-9958(65)90241-X). URL <http://www.sciencedirect.com/science/article/pii/S001999586590241X>.
- [12] Lotfi A Zadeh. The concept of a linguistic variable and its application to approximate reasoning—i. *Information sciences*, 8(3):199--249, 1975.

- [13] Lotfi A. Zadeh. Fuzzy logic, neural networks, and soft computing. *Commun. ACM*, 37(3):77--84, March 1994. ISSN 0001-0782. doi: 10.1145/175247.175255. URL <http://doi.acm.org/10.1145/175247.175255>.
- [14] Βασίλειος Κ. Καρακάσης. Μοντέλα τεχνητών ανοσοποιητικών συστημάτων για την εξόρυξη γνώσης από σύνολα δεδομένων. Master's thesis, Εθνικό Μετσόβιο Πολυτεχνείο, 2005. URL [http://artemis.cslab.ntua.gr/el\\_thesis/artemis.ntua.ece/DT2005-0229/DT2005-0229.pdf](http://artemis.cslab.ntua.gr/el_thesis/artemis.ntua.ece/DT2005-0229/DT2005-0229.pdf).
- [15] Γεώργιος Α. Τσιχριντζής. Σημειώσεις διδασκαλίας για το μάθημα "Αναγνώριση Προτύπων" - Εισαγωγή στην Αναγνώριση Προτύπων. Σημειώσεις μαθήματος, 2014.